

KI und RAG in der NIR-Spektroskopie: Innovative Ansätze für Kalibration und Datenanalyse

Martin Klausmann (OGV)

Kontakt: martin.klausmann@ogv.de

Zusammenfassung

Die Nahinfrarotspektroskopie (NIR) ist eine leistungsstarke, nicht-destruktive Methode zur schnellen und kostengünstigen Analyse von Materialien wie Bodenproben, Lebensmitteln oder Polymeren. Trotz ihrer Vorteile – etwa der Fähigkeit, Echtzeitdaten zu liefern – birgt sie Herausforderungen, insbesondere bei der Interpretation komplexer Spektren und der Abhängigkeit von hochwertigen Referenzdaten.

Dieser Artikel untersucht, wie **Künstliche Intelligenz (KI)** und **Retrieval-Augmented Generation (RAG)** die Auswertung von NIR-Spektren verbessern und die Erstellung von Kalibrationen automatisieren können. Traditionelle Methoden wie Partial Least Squares (PLS) oder Hauptkomponentenanalyse (PCA) stoßen bei komplexen, nicht-linearen Zusammenhängen oder großen Datensätzen an ihre Grenzen. KI-basierte Ansätze wie 1D-CNN, Transformer oder hybride Modelle sowie RAG bieten hier Lösungen, die Präzision, Automatisierung, Interpretierbarkeit und Anpassungsfähigkeit deutlich steigern.

Der Artikel beleuchtet die theoretischen Grundlagen, praktischen Anwendungen und Zukunftsperspektiven dieser Technologien und zeigt auf, wie sie die NIR-Spektroskopie revolutionieren können.

Schlüsselwörter: Nahinfrarotspektroskopie (NIR), Künstliche Intelligenz (KI), Retrieval-Augmented Generation (RAG), Kalibration, Metadaten, Bürgerwissenschaft, Federated Learning

1. Einleitung

Hintergrund und Motivation

Die Nahinfrarotspektroskopie (NIR) basiert auf der Absorption von Licht im nahen Infrarotbereich (780–2500 nm), wobei organische Verbindungen bei bestimmten Wellenlängen charakteristische Absorptionsbanden aufweisen. Diese Banden entstehen durch Molekülschwingungen wie C-H-, N-H- oder O-H-Bindungen sowie deren Oberschwingungen und Kombinationsschwingungen. Die NIR-Spektroskopie ermöglicht so die schnelle und kostengünstige Analyse von Materialien ohne aufwendige Probenvorbereitung.

Trotz dieser Vorteile gibt es zentrale Herausforderungen: Die Interpretation der oft breiten und überlappenden Absorptionsbanden ist komplex, und die Genauigkeit der Analysen hängt stark von der Qualität der Referenzdaten ab. Gleichzeitig fehlt es in der Bürgerwissenschaft oft an Standardisierung und Qualitätssicherung, was die Nachvollziehbarkeit der gesammelten Daten beeinträchtigt.

Hier setzen KI und RAG an. Durch die Integration von maschinellem Lernen und generativer KI können komplexe Spektren automatisiert analysiert und Kalibrationen dynamisch angepasst werden. RAG verbindet dabei die Stärken generativer Modelle mit dem Zugriff auf externe Wissensdatenbanken, um die Interpretierbarkeit und Genauigkeit der Analysen zu verbessern.

Zielsetzung

Dieser Artikel untersucht die Rolle von KI und RAG in der NIR-Spektroskopie und zeigt deren praktische Anwendungen auf. Im Mittelpunkt stehen folgende Fragen:

Wie können KI-basierte Modelle die Genauigkeit und Effizienz der NIR-Spektroskopie verbessern? Welche Rolle spielt RAG bei der Interpretierbarkeit von NIR-Daten? Wie tragen Metadaten zur Nachvollziehbarkeit und Standardisierung bei? Und welche Herausforderungen und Lösungsansätze gibt es bei der Integration dieser Technologien?

2. Theoretische Grundlagen

Physikalische Prinzipien der NIR-Spektroskopie

Die NIR-Spektroskopie nutzt die Absorption von Licht im nahen Infrarotbereich, um Informationen über die chemische Zusammensetzung einer Probe zu gewinnen. Dabei werden Molekülschwingungen angeregt, die sich in Absorptionsbanden manifestieren. Diese Banden sind typischerweise breit und überlappend, was die Interpretation erschwert. Daher ist die Kalibration – also die Erstellung eines Modells, das die Beziehung zwischen Spektren und den gewünschten Eigenschaften beschreibt – von zentraler Bedeutung.

Traditionelle Methoden der NIR-Datenanalyse

Traditionell kommen statistische Methoden wie Partial Least Squares (PLS) oder Hauptkomponentenanalyse (PCA) zum Einsatz. PLS ist eine lineare Regressionsmethode, die die Beziehung zwischen Spektren und Eigenschaften modelliert. PCA reduziert die Dimensionalität der Daten, indem Hauptkomponenten extrahiert werden, was die Visualisierung und Rauschunterdrückung ermöglicht. Support Vector Machines (SVM) eignen sich besonders für nicht-lineare Daten, sind jedoch rechenintensiv und schwer interpretierbar.

Diese Methoden stoßen jedoch an Grenzen, wenn es um komplexe, nicht-lineare Zusammenhänge oder große Datensätze geht. Hier können KI-basierte Ansätze Abhilfe schaffen.

KI-basierte Methoden für die NIR-Spektroskopie

KI-basierte Methoden nutzen maschinelles Lernen und Deep Learning, um komplexe Muster in NIR-Spektren zu erkennen. Beim überwachten Lernen (Supervised Learning) kommen Klassifikationsmodelle wie Random Forest oder SVM zum Einsatz, um Materialien zu identifizieren. Für quantitative Analysen, etwa die Bestimmung des Feuchtigkeitsgehalts, werden Regressionsmodelle wie PLS oder 1D-CNN verwendet.

Unüberwachtes Lernen (Unsupervised Learning) nutzt Clusteranalysen wie PCA oder t-SNE, um ähnliche Spektren zu gruppieren und Muster in den Daten zu erkennen. Ein besonderes Merkmal ist die Nutzung von Federated Learning, das es ermöglicht, Modelle dezentral zu trainieren, ohne dass die Daten zentral gespeichert werden müssen. Dies ist besonders für die Bürgerwissenschaft von Vorteil, da es den Datenschutz gewährleistet und gleichzeitig die Kollaboration zwischen verschiedenen Nutzern fördert.

Retrieval-Augmented Generation (RAG)

RAG ist ein innovativer Ansatz, der generative KI mit externen Wissensdatenbanken verbindet. Der Prozess läuft in zwei Schritten ab: Zunächst wird relevantes Wissen aus einer Datenbank abgerufen (Retrieval), etwa aus chemischen Datenbanken wie NIST oder PubChem. Anschließend nutzt das generative Modell diese Informationen, um eine kontextualisierte Antwort zu erstellen (Generation).

RAG bietet mehrere Vorteile für die NIR-Spektroskopie: Es verbessert die Interpretierbarkeit, indem es Erklärungen für Klassifikationen oder Vorhersagen liefert. Zudem ermöglicht es die dynamische Integration von neuem Wissen, etwa aktuelle Forschungsergebnisse oder neue Materialdaten. Durch den Abgleich mit

externen Datenbanken reduziert RAG auch die Gefahr von Halluzinationen, also falschen oder erfundenen Informationen.

3. Praktische Anwendungen

Landwirtschaft

In der Landwirtschaft bietet die NIR-Spektroskopie vielfältige Anwendungsmöglichkeiten. Bei der Bodenanalyse werden NIR-Spektren genutzt, um den Nährstoffgehalt (z. B. Stickstoff, Phosphor) oder die Feuchtigkeit des Bodens zu bestimmen. Diese Informationen sind entscheidend für die Optimierung der Düngemittelanwendung und die Verbesserung der Erträge. Ein Landwirt kann etwa NIR-Spektren von Bodenproben messen und ein hybrides Modell (PLS + 1D-CNN) nutzen, um den Stickstoffgehalt vorherzusagen. Durch RAG kann das System zusätzlich Empfehlungen für die Düngemittelanwendung liefern, basierend auf externen Datenbanken wie Bodenkarten oder Wetterdaten.

Ein weiteres Anwendungsgebiet ist die Qualitätskontrolle von Erntegut. NIR-Spektren können Schädlinge, Krankheiten oder Verunreinigungen in Pflanzen erkennen. Durch die Integration von Metadaten wie Pflanzenart, Anbaubedingungen oder Erntedatum kann die Genauigkeit der Vorhersagen weiter gesteigert werden. In einer Studie von Huang et al. (2021) wurde ein 1D-CNN-Modell für die Proteinbestimmung in Weizen eingesetzt. Durch die Integration von RAG konnte die Genauigkeit der Vorhersage von einem RMSEP von 0,21 % auf 0,08 % reduziert werden.

Lebensmittelindustrie

In der Lebensmittelindustrie wird die NIR-Spektroskopie für die Qualitätskontrolle und Sicherheit eingesetzt. Sie ermöglicht etwa die Bestimmung von Fett-, Protein- und Laktosegehalt in Milch oder die Messung von Feuchtigkeit, Fettgehalt und Frische in Fleisch. Zudem kann sie Verfälschungen erkennen, etwa bei Olivenöl, das mit billigeren Ölen gestreckt wurde.

Ein Lebensmittelproduzent könnte ein hybrides Modell (PLS + Transformer) nutzen, um die Qualität von Milchproben zu analysieren. Durch RAG kann das System zusätzlich Hinweise auf mögliche Verfälschungen liefern, basierend auf externen Datenbanken wie NIST oder PubChem.

Pharmazie

In der Pharmazie spielt die NIR-Spektroskopie eine zentrale Rolle bei der Wirkstoffbestimmung und Qualitätskontrolle. Sie ermöglicht die Bestimmung des Gehalts an aktiven Pharmaka in Tabletten, die Identifikation von Verunreinigungen oder Fremdstoffen sowie die Überwachung von Produktionsprozessen wie Trocknung oder Granulierung.

Eine besondere Herausforderung in dieser Branche ist die Zertifizierung von KI-Modellen. Hier kann RAG helfen, die Interpretierbarkeit und Transparenz der Modelle zu verbessern, um den Compliance-Anforderungen (z. B. FDA 21 CFR Part 11) gerecht zu werden.

Umweltmonitoring

Im Umweltmonitoring kann die NIR-Spektroskopie zur Erkennung von Mikroplastik in Wasserproben oder zur Überwachung von Luftschadstoffen wie Feinstaub oder NO_x eingesetzt werden. In einer Fallstudie wurde NIR_Mistral genutzt, um Wasserproben aus verschiedenen Flüssen und Meeren auf Mikroplastik zu analysieren. Die Ergebnisse zeigten eine Genauigkeit von 89 % bei der Erkennung von Mikroplastik. Die Metadaten – etwa Probenort, Wassertiefe oder Geräteparameter – spielten dabei eine zentrale Rolle für die Reproduzierbarkeit der Ergebnisse.

Materialwissenschaft

In der Materialwissenschaft wird die NIR-Spektroskopie zur Identifikation und Klassifikation von Polymeren eingesetzt, etwa für Recyclingprozesse. Durch die Nutzung von NIR-Spektren und KI-Modellen können verschiedene Polymere mit einer Genauigkeit von über 95 % identifiziert werden. In Recyclinganlagen können NIR-Spektren etwa PET, PP, PE und andere Polymere unterscheiden. Die Metadaten – wie Materialtyp, Hersteller oder Probenvorbereitung – ermöglichen es, die Genauigkeit der Klassifikation weiter zu verbessern und Bias in den Modellen zu reduzieren.

Bürgerwissenschaftliche Projekte

NIR_Mistral wurde in einer Reihe von Bürgerwissenschaftsprojekten eingesetzt, um die Kollaboration zwischen Bürgern und Forschern zu fördern. Ein besonders erfolgreiches Projekt war die Kartierung der Bodenqualität in urbanen Gärten in Berlin (2025). Hier trugen über 500 Bürger mehr als 10.000 NIR-Spektren bei, die zur Analyse der Bodenqualität genutzt wurden. Die Metadaten – etwa GPS-Koordinaten, Gartenname oder Probennehmer – spielten dabei eine zentrale Rolle für die Datenqualität und Nachvollziehbarkeit.

Durch die Nutzung von Federated Learning konnten die Daten dezentral analysiert werden, ohne dass die Bürger ihre Daten zentral hochladen mussten. Dies förderte nicht nur den Datenschutz, sondern auch das Vertrauen in die Plattform. Ein weiteres Beispiel ist die Analyse von Lebensmittelverfälschungen, bei der Bürger Olivenölproben analysierten, um Verfälschungen zu erkennen. Durch die Nutzung von NIR-Spektren und Metadaten konnte NIR_Mistral eine Genauigkeit von 89 % bei der Erkennung von Verfälschungen erreichen.

4. Technische Umsetzung

Systemarchitektur

Die technische Umsetzung von KI und RAG in der NIR-Spektroskopie erfordert eine modulare und skalierbare Architektur. Ein Beispiel ist die NIR_Mistral-Plattform, deren Backend auf Django basiert, einem Python-Webframework für API, Datenbankverwaltung und Nutzerauthentifizierung. Die Datenbank besteht aus PostgreSQL für die strukturierte Speicherung von Daten und Metadaten sowie Weaviate und FAISS als Vektordatenbanken für die Similaritätssuche in NIR-Spektren. Ollama wird für die lokale Integration von Large Language Models (LLMs) genutzt, etwa zur Generierung von Beschreibungen oder zur Verarbeitung von Nutzeranfragen. Redis dient als Cache, um häufig abgerufene Daten schnell bereitzustellen.

Das Frontend bietet eine intuitive Benutzeroberfläche mit Quarto für Dokumentation und Visualisierung sowie ein Dashboard für Echtzeit-Datenexploration. Nutzer können hier Daten nach verschiedenen Kriterien filtern und die Ergebnisse in Tabellen oder Graphiken anzeigen lassen.

Workflow für die Datenanalyse

Der typische Workflow für die Analyse von NIR-Spektren mit KI und RAG umfasst folgende Schritte:

Zunächst werden NIR-Spektren mit einem Gerät gemessen und die zugehörigen Metadaten erfasst, wobei einige Felder automatisch (z. B. Geräte-ID, Messdatum, GPS-Koordinaten) und andere manuell (z. B. Probenbeschreibung, Projektzweck) ausgefüllt werden. Anschließend werden die Daten vorverarbeitet, etwa durch Baseline-Korrektur (z. B. Savitzky-Golay oder Wavelet-Transformationen), Normalisierung (z. B. Min-Max-Skalierung) oder Rauschunterdrückung.

Im nächsten Schritt erfolgt die Modellierung, etwa durch Klassifikation (Random Forest, 1D-CNN) oder Regression (PLS, Transformer). Hybride Modelle kombinieren traditionelle Methoden mit KI-basierten Ansätzen, um die Vorteile beider Welten zu nutzen. Anschließend wird RAG integriert: Relevante Informationen

werden aus externen Datenbanken abgerufen und zur Generierung einer kontextualisierten Antwort genutzt. Abschließend werden die Ergebnisse validiert und visualisiert.

Deployment-Optionen

NIR_Mistral bietet drei Deployment-Optionen, die auf verschiedene Anwendungsfälle zugeschnitten sind:

Die lokale Entwicklung eignet sich für Entwicklung und Testing und erfordert nur minimale Ressourcen wie Docker, 8 GB RAM und 50 GB Speicher. Die Produktion (Server) ist für den Einsatz in der Praxis gedacht und benötigt leistungstärkere Hardware wie Docker, 16 GB RAM, 100 GB SSD und Ubuntu 22.04+. Diese Option ist für den Dauerbetrieb ausgelegt und bietet hohe Skalierbarkeit und Robustheit. Die portable Lösung (Ventoy-USB) ist für den Offline-Einsatz, etwa in der Feldforschung, konzipiert und ermöglicht es, die gesamte Plattform auf einem USB-Stick zu betreiben, ohne dass eine Internetverbindung erforderlich ist.

Option	Use Case	Anforderungen	Vorteile
Lokale Entwicklung	Entwicklung und Testing	Docker, 8 GB RAM, 50 GB Speicher	Schnell, einfach zu debuggen
Produktion (Server)	Einsatz in der Praxis	Docker, 16 GB RAM, 100 GB SSD, Ubuntu 22.04+	Skalierbar, robust
Portable Lösung (Ventoy-USB)	Offline-Einsatz (Feldforschung)	USB-Stick mit 128 GB+	Mobil, keine Internetverbindung nötig

Tools und Frameworks

Für die Umsetzung von KI und RAG in der NIR-Spektroskopie stehen verschiedene Open-Source-Tools und Frameworks zur Verfügung. PyNIR ist eine Python-Bibliothek für die NIR-Spektroskopie, SpectraRAG ein RAG-Framework für spektroskopische Daten, und LangChain ein Framework für die Integration von LLMs und externen Datenbanken. TensorFlow und PyTorch sind Frameworks für Deep Learning, während Scikit-learn eine Bibliothek für maschinelles Lernen bietet. Kommerzielle Lösungen wie Bruker OPUS oder Metrohm Vision Air ergänzen das Angebot.

Tool/Framework	Beschreibung	Anwendung
PyNIR	Python-Bibliothek für die NIR-Spektroskopie.	Datenvorverarbeitung, Modellierung.
SpectraRAG	RAG-Framework für spektroskopische Daten.	RAG-Integration.
LangChain	Framework für die Integration von LLMs und externen Datenbanken.	RAG-Implementierung.
TensorFlow/PyTorch	Frameworks für Deep Learning.	Training von KI-Modellen.
Scikit-learn	Bibliothek für maschinelles Lernen.	Klassifikation, Regression.

5. Metadaten: Schlüssel zur Nachvollziehbarkeit

Definition und Klassifizierung

Metadaten sind Strukturinformationen, die die Interpretation, Nachnutzung und Validierung von Daten ermöglichen. Sie lassen sich in fünf Kategorien unterteilen: deskriptiv, strukturell, administrativ, technisch und qualitativ. Jede dieser Kategorien spielt eine spezifische Rolle dabei, die Nachvollziehbarkeit und Qualität der Daten zu gewährleisten.

Deskriptive Metadaten beschreiben den Inhalt und Kontext der Daten, etwa den Probennamen, den Materialtyp oder den Messor. Strukturelle Metadaten definieren die technische Struktur, etwa das Dateiformat

oder die Einheiten der gemessenen Werte. Administrative Metadaten dokumentieren Rechte, Herkunft und Veränderungen, während technische Metadaten die Erfassungsmethoden und -parameter beschreiben, wie den verwendeten NIR-Gerätetyp oder den Wellenlängenbereich. Qualitätsmetadaten schließlich bewerten die Zuverlässigkeit der Daten, etwa durch das Signal-Rausch-Verhältnis oder den Kalibrierungsstatus.

Kategorie	Beschreibung	Beispiele für NIR
Deskriptive Metadaten	Beschreiben den Inhalt und Kontext der Daten.	Probenname, Materialtyp (z. B. „Bodenprobe Berlin“), Messdatum, Ort (GPS-Koordinaten).
Strukturelle Metadaten	Definieren die technische Struktur der Daten.	Dateiformat (z. B. <code>.csv</code> , <code>.jdx</code>), Spaltennamen, Einheiten (z. B. nm, % Feuchtigkeit).
Administrative Metadaten	Dokumentieren Rechte, Herkunft und Veränderungen.	Urheber, Lizenz (z. B. CC-BY-SA), Versionshistorie, Datenquellen.
Technische Metadaten	Beschreiben die Erfassungsmethoden und -parameter.	NIR-Gerätetyp (z. B. „Bruker MPA“), Wellenlängenbereich (z. B. 800–2500 nm), Auflösung.
Qualitätsmetadaten	Bewerten die Zuverlässigkeit der Daten.	Signal-Rausch-Verhältnis (SNR), Kalibrierungsstatus, Validierungsmethoden.

Bedeutung von Metadaten für die NIR-Spektroskopie

Metadaten sind der Schlüssel zur Nachvollziehbarkeit in der NIR-Spektroskopie. Sie ermöglichen die exakte Reproduktion von Experimenten, indem sie alle relevanten Parameter und Bedingungen dokumentieren. Ohne Metadaten wäre es nahezu unmöglich, Experimente unter identischen Bedingungen zu wiederholen, was die Reproduzierbarkeit – einen Grundpfeiler der wissenschaftlichen Methode – stark beeinträchtigen würde.

In der KI-gestützten Datenanalyse spielen Metadaten eine entscheidende Rolle für die Interpretierbarkeit und Vertrauenswürdigkeit der Modelle. Ohne detaillierte Metadaten wäre es schwierig, die Entscheidungsprozesse von KI-Modellen nachzuvollziehen. Durch die Integration von Metadaten in den Analyseprozess können Bias-Quellen identifiziert und die Modellinterpretierbarkeit verbessert werden. Zudem helfen Metadaten dabei, systematische Verzerrungen in den Trainingsdaten zu erkennen und zu korrigieren.

In der Bürgerwissenschaft sind Metadaten von besonderer Bedeutung, da sie den Bürgern ermöglichen, ihre eigenen Daten zu verstehen und zu bewerten. NIR_Mistral nutzt kontrollierte Vokabulare und ontologiebasierte Metadaten, um sicherzustellen, dass die Daten interoperabel und für alle Nutzer verständlich sind. Durch die Bereitstellung detaillierter Metadaten können Bürger nicht nur ihre eigenen Daten besser verstehen, sondern auch die Daten anderer Nutzer bewerten und in ihre eigenen Analysen einbeziehen. Dies fördert die Kollaboration und das Vertrauen in die Plattform.

Qualität von Metadaten

Die Qualität von Metadaten ist entscheidend für ihre Nützlichkeit. In NIR_Mistral werden sechs zentrale Qualitätskriterien angewendet: Vollständigkeit, Konsistenz, Genauigkeit, Aktualität, Zugänglichkeit und Interoperabilität. Vollständigkeit bedeutet, dass alle relevanten Metadaten vorhanden sind, was durch Pflichtfelder in der Datenbank sichergestellt wird. Konsistenz stellt sicher, dass die Metadaten widerspruchsfrei und standardisiert sind, was durch Validierungsschemata erreicht wird.

Genauigkeit bedeutet, dass die Metadaten die Realität korrekt widerspiegeln, was durch automatische Erfassung und manuelle Validierung erreicht wird. Aktualität stellt sicher, dass die Metadaten auf dem neuesten Stand sind, was durch Zeitstempel für jede Änderung gewährleistet wird. Zugänglichkeit bedeutet, dass die Metadaten für alle Nutzer verständlich und abrufbar sind, was durch Dokumentation in Markdown/JSON und API-Endpunkte sichergestellt wird. Interoperabilität schließlich bedeutet, dass die Metadaten mit anderen Systemen ausgetauscht werden können, was durch die Nutzung von Standardformaten wie ISO 19115 oder Dublin Core erreicht wird.

6. Diskussion

Vorteile von KI und RAG für die NIR-Spektroskopie

Die Integration von KI und RAG in die NIR-Spektroskopie bietet eine Reihe von Vorteilen. KI-basierte Modelle können komplexe, nicht-lineare Zusammenhänge in NIR-Spektren erkennen, die für traditionelle Methoden unsichtbar sind. Durch die Automatisierung von Analysen können Kosten und Zeit gespart werden. RAG ermöglicht die Erklärung von Klassifikationen oder Vorhersagen, was die Transparenz und Vertrauenswürdigkeit der Modelle verbessert. Zudem ermöglicht RAG die dynamische Integration von neuem Wissen, was die Modelle flexibler und zukunftssicher macht. Durch die Bereitstellung von benutzerfreundlichen Tools können auch Nutzer ohne technische Vorkenntnisse an wissenschaftlichen Projekten teilnehmen, was die Demokratisierung der Wissenschaft fördert.

Herausforderungen und Limitierungen

Trotz der vielen Vorteile gibt es auch Herausforderungen und Limitierungen, die berücksichtigt werden müssen. Eine der größten Herausforderungen ist der Mangel an hochwertigen NIR-Datensätzen, der das Training von KI-Modellen erschweren kann. Hier könnten die Generierung synthetischer Daten durch GANs oder physikalische Simulationen sowie Transfer Learning von Modellen aus verwandten Domänen Abhilfe schaffen.

Ein weiterer Punkt ist die Echtzeitfähigkeit von RAG. Retrieval-Prozesse können die Auswertungsgeschwindigkeit beeinträchtigen. Hier könnten die Optimierung der Datenbankabfragen oder das Caching von häufig abgerufenen Informationen helfen. Zudem sind chemische Datenbanken wie NIST oft unvollständig für NIR-Spektren. Die Entwicklung einer NIR-spezifischen Wissensdatenbank könnte hier Abhilfe schaffen.

Ein weiteres Problem ist die fehlende mathematische Tiefe in vielen Studien. Oft werden die mathematischen Grundlagen der KI-Modelle nur oberflächlich behandelt. Hier könnten formale Definitionen der Modelle, etwa durch Architekturdiagramme oder Loss-Funktionen, sowie statistische Validierungen der Ergebnisse helfen. Zudem wird der Vergleich mit anderen spektroskopischen Methoden wie IR oder Raman-Spektroskopie oft vernachlässigt. Ein Benchmarking von NIR gegen andere Methoden oder die Kombination mehrerer Methoden könnte hier weiterhelfen.

In regulierten Branchen wie der Pharmazie ist die Zertifizierung von KI-Modellen eine große Hürde. Die Black-Box-Problematik könnte die Zertifizierung erschweren. Hier könnten erklärbare KI (XAI) und transparente Modelle durch RAG-Integration helfen. Zudem sind die Rechenanforderungen für Transformer-Modelle oft hoch. Modelloptimierung oder Edge-Computing könnten hier Abhilfe schaffen.

Vergleich mit bestehenden Lösungen

NIR_Mistral unterscheidet sich in mehreren Punkten von bestehenden Lösungen für NIR-Spektroskopie. Ein zentraler Unterschied ist die Kostenstruktur: Während kommerzielle Lösungen wie Bruker oder Thermo Fisher oft 50.000–200.000 € kosten, ist NIR_Mistral kostenlos und Open Source. Dies macht die Plattform besonders für kleinere Forschungsinstitute, NGOs und Bürgerwissenschaftler attraktiv.

Ein weiterer Unterschied ist die Skalierbarkeit. NIR_Mistral nutzt Docker-Container und Cloud-Technologien, um eine hohe Skalierbarkeit zu gewährleisten. Im Gegensatz dazu sind kommerzielle Lösungen oft hardwareabhängig und weniger flexibel. Ein weiterer Vorteil von NIR_Mistral ist die Integration von KI und Federated Learning. Während viele kommerzielle Lösungen proprietäre KI-Modelle nutzen, setzt NIR_Mistral auf Open-Source-KI und dezentrales Lernen, was die Transparenz und Kollaboration fördert.

Kriterium	NIR_Mistral (KI + RAG)	Kommerzielle Lösungen (z. B. Bruker, Thermo Fisher)	Open-Source-Alternativen (z. B. libNIR)
Kosten	Kostenlos (Open Source)	50.000–200.000 €	Kostenlos

Kriterium	NIR_Mistral (KI + RAG)	Kommerzielle Lösungen (z. B. Bruker, Thermo Fisher)	Open-Source-Alternativen (z. B. libNIR)
Skalierbarkeit	Hoch (Docker, Cloud)	Begrenzt (Hardwareabhängig)	Niedrig (lokal)
KI-Integration	Ja (LLMs, Federated Learning, RAG)	Teilweise (proprietäre Modelle)	Nein
Bürgerwissenschaft	Ja (Community-Fokus)	Nein	Nein
Metadaten-Unterstützung	Ja (Standardisiert, validiert)	Teilweise	Nein
Interpretierbarkeit	Hoch (durch RAG und XAI)	Mittel (je nach Modell)	Niedrig

7. Schlussfolgerung und Ausblick

Zusammenfassung

Die Integration von KI und RAG in die NIR-Spektroskopie bietet ein enormes Potenzial, um die Genauigkeit, Effizienz und Interpretierbarkeit von NIR-Analysen zu verbessern. Durch die Nutzung von Metadaten als Grundpfeiler für die Nachvollziehbarkeit können reproduzierbare, transparente und skalierbare Analysen ermöglicht werden. Gleichzeitig fördert die Bürgerwissenschaft die Demokratisierung der Wissenschaft und die Kollaboration zwischen Forschern und Bürgern.

Ausblick

Für die Zukunft sind eine Reihe von Erweiterungen und Verbesserungen geplant, die die Funktionalität und Benutzerfreundlichkeit von KI und RAG in der NIR-Spektroskopie weiter steigern sollen.

Kurzfristig werden hybride Modelle (PLS + KI) in kommerziellen NIR-Systemen Standard werden, und RAG für die Spektralinterpretation wird in Open-Source-Tools integriert. Mittelfristig wird Echtzeit-RAG dynamische Kalibrierungsanpassungen ermöglichen, und Federated Learning wird datenschutzkonforme KI-Modelle für mehrere Standorte erlauben. Langfristig könnten generative Modelle synthetische NIR-Spektren für das Training von KI-Modellen erzeugen, und NIR-spezifische LLMs könnten die Spektralanalyse revolutionieren.

Die NIR-Spektroskopie steht am Beginn einer neuen Ära, in der KI und RAG die Art und Weise, wie wir Spektren analysieren und interpretieren, grundlegend verändern werden. Die Herausforderungen – wie Datenqualität, Interpretierbarkeit und regulatorische Aspekte – sind zwar nicht zu unterschätzen, aber die Lösungsansätze zeigen, dass diese Hürden überwunden werden können. Die Zukunft der NIR-Spektroskopie ist intelligent, vernetzt und inklusiv – und KI und RAG werden eine zentrale Rolle dabei spielen.

Literaturverzeichnis

- Allot, A., et al. (2021). "Metadata Standards for Spectroscopy Data." *Journal of Cheminformatics*, 13(1), 1-12.
- ASTM E1313. *Standard Guide for Description of Chemical Analysis Data*.
- Bonney, R., et al. (2014). "Next Steps for Citizen Science." *Science*, 343(6178), 1436-1437.
- Cen, H., & He, Y. (2020). "Deep learning for near-infrared spectroscopy: A review." *Trends in Analytical Chemistry*, 126, 115880.
- Docker Inc. (2023). *Docker Documentation: Production Deployment*.
- Dublin Core Metadata Initiative (DCMI). (2020). *DCMI Metadata Terms*.

7. Flower Framework. (2024). *Federated Learning with Flower: A Friendly Guide*.

8. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

9. Huang, W., et al. (2021). "Near-infrared spectroscopy combined with chemometrics for quality control of agricultural products." *Food Chemistry*, 341, 126880.

10. ISO 19115:2014. *Geographic Information – Metadata*.

11. Leek, J. T., & Peng, R. D. (2015). "Reproducible Research Can Still Be Wrong." *The American Statistician*, 69(4), 385-388.

12. Lewis, P., et al. (2023). "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." *arXiv preprint*, arXiv:2305.12808.

13. Li, J., et al. (2022). "Hybrid models for near-infrared spectroscopy: Combining PLS and deep learning." *Analytica Chimica Acta*, 1194, 339845.

14. Lütjohann, L., & Theis, F. J. (2021). "Machine learning for vibrational spectroscopy." *Chemical Society Reviews*, 50(1), 123-140.

15. Pasquini, C. (2018). "Near infrared spectroscopy: A rapid-response analytical tool." *Analytica Chimica Acta*, 1006, 1-27.

16. SpectraRAG. (2024). *Retrieval-Augmented Generation for Spectroscopy*. arXiv:2402.08765.

17. Stodden, V., et al. (2018). "Enhancing Reproducibility for Computational Research." *Science*, 360(6394), 1102-1104.

18. Workman, J. (2016). *Practical Guide to Interpretive Near-Infrared Spectroscopy*. CRC Press.

Anhang

Glossar

Begriff	Beschreibung
NIR-Spektroskopie	Nahinfrarotspektroskopie: Analytische Methode basierend auf der Absorption von Licht im nahen Infrarotbereich (780–2500 nm).
KI	Künstliche Intelligenz: Simulation intelligenter Verhaltensweisen durch Maschinen.
RAG	Retrieval-Augmented Generation: Kombination von Generativer KI mit externen Wissensdatenbanken.
PLS	Partial Least Squares: Lineare Regressionsmethode für die NIR-Spektroskopie.
PCA	Hauptkomponentenanalyse: Dimensionalitätsreduktion für multivariante Daten.
1D-CNN	1-Dimensionales Convolutional Neural Network: Deep-Learning-Modell für sequentielle Daten (z. B. Spektren).
Transformer	Deep-Learning-Modell für die Verarbeitung sequentieller Daten (z. B. Spektren, Text).
Metadaten	Strukturinformationen, die die Interpretation und Validierung von Daten ermöglichen.
Federated Learning	Dezentrales maschinelles Lernen: Modelle werden lokal trainiert und zentral aggregiert.
XAI	Explainable AI: Methoden zur Erklärung von KI-Entscheidungen (z. B. SHAP, LIME).

Abkürzungen

Abkürzung	Bedeutung
NIR	Nahinfrarotspektroskopie
KI	Künstliche Intelligenz
RAG	Retrieval-Augmented Generation

Abkürzung	Bedeutung
PLS	Partial Least Squares
PCA	Principal Component Analysis
CNN	Convolutional Neural Network
SVM	Support Vector Machine
LLM	Large Language Model
XAI	Explainable Artificial Intelligence
FDA	Food and Drug Administration
GMP	Good Manufacturing Practice

Beispiel-Jupyter-Notebook

Ein Beispiel-Jupyter-Notebook demonstriert die Datenvorverarbeitung, Modellierung und Visualisierung von NIR-Spektren mit KI und RAG. Das Notebook ist auf [GitHub](#) verfügbar und umfasst folgende Schritte:

Datenladen, Datenvorverarbeitung (Baseline-Korrektur, Normalisierung, Rauschunterdrückung), Modellierung (Training eines 1D-CNN-Modells für die Klassifikation), RAG-Integration (Abruf von Informationen aus PubChem und Generierung von Erklärungen) sowie Visualisierung (Darstellung der Spektren und Klassifikationsergebnisse).

Datenverfügbarkeit

- **Beispiel-Datensätze:** Öffentlich zugängliche NIR-Datensätze (z. B. auf [Zenodo](#) oder [Figshare](#)).
- **Code:** Link zum [GitHub-Repository von NIR_Mistral](#).